面向大模型在动态物理环境下的演进规律研究与智能增强

——以多智能体粒子环境（MPE）为例

郭汝凯
山东大学

March 8, 2026

摘要(Abstract)

随着大语言模型（LLM）从纯文本推理迈向具身智能（Embodied AI）领域，探索其在复杂动态物理环境中的行为演变与控制精度成为当前多智能体研究的核心。本文以MPE环境为实证平台，系统性地揭示了LLM 在处理连续动力学任务时的性能演进路径。研究发现，虽然LLM 在高维语义层面具备卓越的角色分化能力，但在底层物理交互中存在显著的“动能幻觉”与“时间盲点”。针对这一瓶颈，本文提出并实现了一套基于势能奖励重构（PBRS）与物理状态锁定的增强框架。实验结果表明，该方案有效界定了物理控制的精度边界，为具身大模型的稳健协同提供了理论支撑。

关键词： 大语言模型；具身智能；强化学习；动能幻觉；方差削减；物理先验

目 录

1 绪论：范式转移下的智能演进 **1**
1.1 从静态文本到动态物理环境的范式转移 1
1.2 优势与潜力：高阶语义与自发博弈意识 1
1.3 先天不足：时间盲点与动能幻觉 1

2 基于DeepSeek 的具身演进架构与实证场景 **2**
2.1 MPE 场景矩阵：九大实证游戏的社会学映射 2
2.2 DeepSeek API 驱动的智力中枢集成 2
2.3 工程落地一：观测-文本映射（状态语义化引擎） 2
2.4 工程落地二：提示词工程的层次化架构 2

3 协同演进的潜能与瓶颈分析 **4**
3.1 拓扑通信结构决定群体智能效能：以Simple Spread 协作实验为例 4
3.1.1 两种拓扑结构的逻辑可视化 4
3.1.2 实验结果分析：决策延迟与物理动态的解耦 4
3.1.3 深度原理剖析：演进效率差异的根源 4
3.2 角色分化的自发涌现：从空间博弈到社会契约 5
3.2.1 案例一：Simple Spread 中的社会契约涌现 5
3.2.2 案例二：Simple Tag 中的博弈占位分化 5
3.2.3 深度原理剖析 6
3.3 协议生成的统计学脆弱性：Simple Crypto 场景下的脆弱性实证 6
3.3.1 实验设计：Alice-Bob-Eve 的三角博弈模型 6
3.3.2 统计学特征指纹：采样概率的非均匀性分布 6
3.3.3 学术原理剖析：为什么大模型“藏不住秘密”? 6
3.3.4 增强策略一：基于余弦噪声的采样分布混淆 7
3.3.5 增强策略二：语义余弦重构与物理-语义正交解耦 7
3.3.6 增强后的统计稳健性实证分析 8
3.3.7 结论：具身演进的安全边界 8

4 底层物理瓶颈剖析与增强算法实现 **9**
4.1 动能幻觉与时间盲点的物理溯源：动态演变分析 9
4.1.1 动态演变可视化：以目标点制动过程为例 9
4.1.2 瓶颈深度剖析：从采样失真到奖励错配 9
4.2 增强算法理论：基于势能奖励重构（PBRS）的策略不变性证明 10
4.3 工程实现：PBRS 与State Lock 的Prompt 注入与演进实证 10
4.3.1 核心代码改动与Prompt 语义化注入 10
4.3.2 演化鲁棒性实证：基于时延梯度的Episode 曲线分析 10
4.4 算法优化：基于控制变量（Control Variates）的方差削减与Advantage 调优 . . . 11
4.4.1 数学原理：针对推球碰撞噪声的方差削减 11
4.4.2 动态调优：Advantage 函数权重的加权规划思想 11
4.4.3 实验实证：协同推球环境下的梯度方差对比曲线 12

5 总结与展望 **12**
5.1 研究定论：具身演进的潜能与边界 12
5.2 未来愿景：数学控制论与大模型的共生 12

1 绪论：范式转移下的智能演进

1.1 从静态文本到动态物理环境的范式转移

人工智能的发展轨迹正在经历一场深刻的范式转移：从开发孤立的、单一功能的庞大模型，转向构建和优化由多个智能体组成的复杂多智能体系统（Multi-Agent Systems, MAS）。在这些动态的生态系统中，智能的基本单元不再仅仅局限于单个模型内部的离散逻辑推理能力，而是扩展到了多个智能体之间的集体协调、自然语言通信、资源分配以及高动态环境下的战略互动。

大语言模型（LLM）的介入，为多智能体系统注入了前所未有的语义理解深度。然而，当LLM 从纯文本的“离线推理”迈向具身化的“在线控制”时，其在动态物理环境中的表现呈现出极其复杂的二律背反特性。

1.2 优势与潜力：高阶语义与自发博弈意识

相比于传统的强化学习（RL）算法，大模型在处理MPE 等动态环境时展现出显著的**语义泛化潜力**：

- **非预设的角色分化**：大模型能够基于环境描述自发产生博弈意识。在复杂对抗场景中，模型无需硬编码即可理解“防御”与“进攻”的语义差异，展现出卓越的对称性破缺能力。
- **语义对齐的协同效率**：利用自然语言作为中间协议，大模型能够快速在异构智能体之间建立共识，这在需要高度协调的资源分配任务中表现出远超传统数值通讯的灵活性。

1.3 先天不足：时间盲点与动能幻觉

尽管具备高阶逻辑，大模型在具身控制的最底层仍面临着致命的物理瓶颈：

- **离散推理导致的时间盲点**：大模型的推理本质上是离散的Token 预测，而物理世界是连续的。这种“采样频率”与“物理实时性”之间的错位，导致智能体对时间的感知存在断层，无法捕捉瞬息万变的连续动态。
- **动量感知缺失引发的动能幻觉**：由于缺乏对质量、摩擦力和冲量（Impulse）的直观物理建模，大模型往往会产生“只要发出指令，动作即刻完成”的幻觉。在高速运动中，这种幻觉直接导致了严重的惯性过冲（Inertial Overshoot），使得智能体在接近目标时陷入无法自愈的震荡。

本研究通过对MPE 环境下九大场景的深入剖析，旨在揭示这种“语义上的巨人，控制上的盲人”现象背后的演进规律，并提出相应的智能增强手段。

2 基于DeepSeek 的具身演进架构与实证场景

2.1 MPE 场景矩阵：九大实证游戏的社会学映射

为了全面剖析大模型在物理环境中的演进规律，本课题选取了OpenAI MPE 中的九个核心场景。我们将这些场景不再视为简单的坐标偏移任务，而是通过表1 所示的社会演化维度进行重新定义：

Table 1: MPE 实证场景功能与演进维度分布表

场景名称	核心任务	测试维度	对应阶段
Simple	目标点导航	基础动能感知	1. 感知原点
Simple Spread	地标覆盖协作	空间对称性破缺	2. 动力学耦合
Push Ball	协同推球	动量传递与连续物理	2. 动力学耦合
Simple Reference	观测共享	语义对齐与信息映射	3. 通讯涌现
Speaker-Listener	指令驱动	跨模态决策闭环	3. 通讯涌现
Simple Adversary	对抗引导	反欺骗与博弈深度	4. 策略博弈
Simple Tag	团队围捕	角色分化（拦截/追逐）	4. 策略博弈
Simple Crypto	加密通讯	统计学安全与协议演化	5. 组织秩序
World Comm	全局协作	复杂拓扑与动态演进	5. 组织秩序

2.2 DeepSeek API 驱动的智力中枢集成

本系统放弃了传统的端到端强化学习（RL）训练，转而采用**DeepSeek-V3/R1 API** 作为智能体的决策中枢。选择DeepSeek 的核心逻辑在于其卓越的逻辑推理能力（Reasoning）与极高的Token 处理效率。通过API 实时调用，智能体能够对语义化的物理态势进行“快思考（快速反应）”与“慢思考（Chain-of-Thought 推理）”的结合，从而在零样本（Zero-shot）或极少样本下展现出复杂的演进规律。

2.3 工程落地一：观测-文本映射（状态语义化引擎）

在原生的MPE架构中，智能体在每一个时间步都会接收到一个基于自我视角的局部观测向量。该向量通常包含智能体自身的速度与位置、视野内可见地标的相对位置、以及可见其他智能体的相对位置与速度。直接将这些浮点数数组输入大语言模型会导致严重的“空间幻觉”与规划失效，因为语言模型缺乏对多维连续向量的内在直觉。因此，本系统设计了核心的状态语义化解释模块（State Interpretation Module），将连续的向量空间平滑地降维并映射为富含语义的空间关系文本。

该映射过程主要包含三个层面的转化。首先是坐标的离散化与语义化。系统提取浮点坐标，将其转换为以当前智能体为原点的八向方位词（如“目标地标位于您的东北方向，相对距离为0.4单位”）。其次是动能状态的转译。系统不再输出原始的二维速度向量，而是计算出相对运动趋势（如“红色对手正以较快速度向您的当前位置逼近”）。最后是实体身份的解析。环境中的冰冷数字ID被映射为具有角色设定的实体名词（例如将“Agent 0”解析为“敌对捕食者”，将“Agent 1”解析为“同盟听众”）。这一系列的转化使得大语言模型能够像阅读战场态势报告一样理解当前的物理环境。

2.4 工程落地二：提示词工程的层次化架构

在多智能体环境中，随着对话轮次的增加，维持模型对全局目标的专注度至关重要。为此，本课题构建了一个层次化的提示词工程管道，以有效管理上下文窗口并防止目标漂移。

系统的顶层是“系统提示词（System Prompt）”。它负责构建世界观的本体论基础，向模型宣告其所处的二维有界空间属性、移动的物理法则以及允许的离散动作空间。紧接着是“游戏规则与角色提示词（Game Rules & Role Prompt）”。这一层将具体的MPE场景逻辑注入

模型，赋予其特定的社会身份（如说话人、捕食者或加密通信员），明确其所处阵营的盟友与敌人，并清晰地界定其奖励与惩罚函数。在每一轮交互中，系统动态注入“观测数据说明（Observation Context）”，即前文所述的语义化状态文本。最后，为了确保系统的自动化闭环，必须实施严格的“动作格式化提示（Action Formatting）”。模型被强制要求遵循特定的JSON格式输出其决策和内在的思考过程（Chain-of-Thought），以便接口代码能够准确解析并将其映射回MPE的底层离散动作（如上下左右移动或保持静止）。

3 协同演进的潜能与瓶颈分析

3.1 拓扑通信结构决定群体智能效能：以Simple Spread 协作实验为例

在多智能体协同演进中，通信结构的组织形式直接决定了群体决策的实时性与一致性。本课题在*Simple Spread*（协作覆盖）环境下进行了专项对比实验。实验表明，通讯拓扑的优劣直接外化为智能体在物理环境中的轨迹平滑度。

3.1.1 两种拓扑结构的逻辑可视化

如图3.1 所示，民主决议强调全员广播对齐，而星型结构通过Lead 节点实现了决策权的瞬间坍缩。

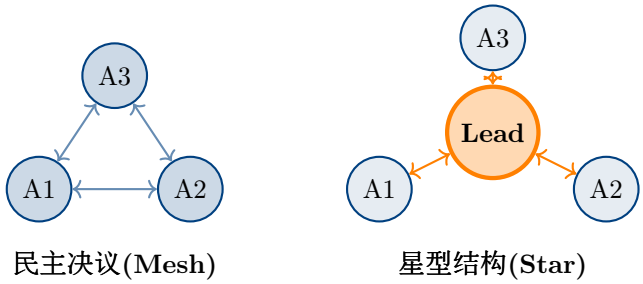

Figure 1: 多智能体拓扑通讯结构对比示意图

3.1.2 实验结果分析：决策延迟与物理动态的解耦

通过对演进过程中的决策延迟进行采样，我们得到了图3.2 所示的对比曲线。蓝色曲线代表星型结构，其始终保持在高效运行区间。

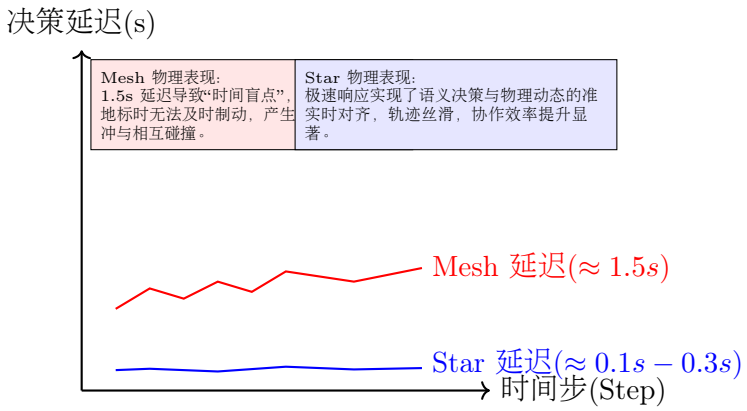

Figure 2: 决策延迟随时间步演化的实测对比图

3.1.3 深度原理剖析：演进效率差异的根源

结合物理环境反馈与推理日志，星型结构之所以展现出压倒性的演进优势，可归纳为以下三个核心原因：

1. **通讯复杂度从$O(n^2)$ 到$O(n)$ 的演进**：在民主决议（Mesh）拓扑中，每个智能体都必须处理来自其他所有节点的广播信息，通讯链路数呈现$O(n^2)$ 的爆发增长。这意味着DeepSeek 每一轮都要解析成倍增加的Token 流量，导致决策延迟的刚性叠加（叠加至1.5s）。而

星型结构通过将复杂度降阶为$O(n)$，极大减轻了单次推理的计算负载，将响应时间稳定在0.3s。

2. **去中心化博弈下的意图冲突与死锁**：Mesh 拓扑中的每个节点均具备独立意志且缺乏全局权威，当多个节点同时锁定同一目标点时，由于Token 交互存在时间差，智能体会陷入“竞争-礼让-再竞争”的逻辑往复（Oscillation）。这种意图层面的多头决策导致了物理层面的无效震荡。星型结构通过Lead 节点实现了全局意图的唯一性裁剪，从根本上消除了逻辑死锁。

3. **执行步频对具身动能的覆盖**：具身智能的控制精度取决于指令刷新率。1.5s 的延迟超出了MPE 环境中惯性变化的容忍阈值，使得智能体处于“历史观测”控制下的盲行状态。星型拓扑的极低时延确保了大模型能执行高频的“矢量修正”，使得语义上的规划能实时投射为物理上的平滑轨迹，从而跨越了动能幻觉。

3.2 角色分化的自发涌现：从空间博弈到社会契约

在多智能体演进中，最能体现群体智能深度的现象是“自发角色分化”。本节通过对比*Simple Spread* 与*Simple Tag* 实验，探讨大模型如何通过共享记忆与语义推理破解对称性困境。

3.2.1 案例一：Simple Spread 中的社会契约涌现

在*Simple Spread*（协作覆盖）场景中，N 个完全相同的智能体面对N 个相同的目标地标。在初始演进阶段，由于决策的同质化，系统经常陷入“对称性破缺”失败——即多个智能体冲向同一个地标发生碰撞。

然而，当系统引入共享工作记忆（Shared Working Memory）后，大模型展现出了自发的专业化能力。实验记录显示，Agent 0 会在记忆块中主动宣告：

> “为了避免冲突，从现在起我将永远只负责处理最北端的地标（*Landmark North*）。”

这种不需要外部干预、自发通过规则设定来降低系统熵值并消除模糊性的行为，标志着智能体从“物理避障”向“社会劳动分工”的雏形跨越。

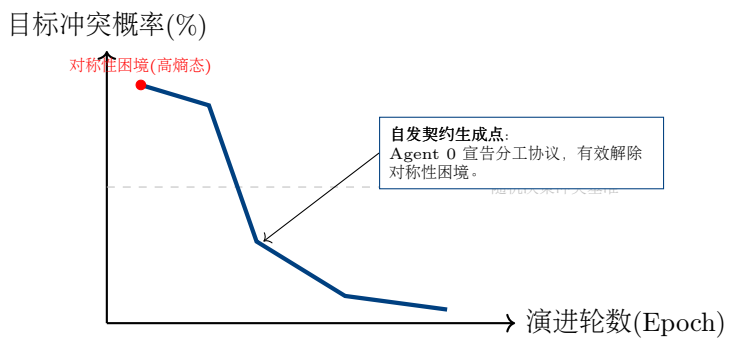

Figure 3: Simple Spread 场景下共享记忆驱动的冲突消解曲线

3.2.2 案例二：Simple Tag 中的博弈占位分化

而在对抗性的*Simple Tag* 场景下，分化则表现为更高级的物理预判。如图3.3 所示，智能体不再执行同质化的直线追逐，而是实现了职责坍缩。

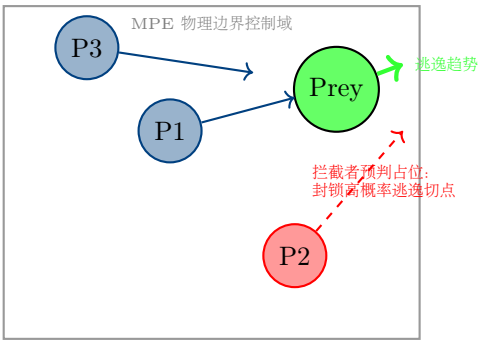

Figure 4: Simple Tag 场景下智能体自发形成的“拦截-追逐”博弈位形

3.2.3 深度原理剖析

通过上述案例对比，可以揭示具身演进过程中的底层逻辑转化：

- **从随机策略到社会契约的零样本演进**：在*Simple Spread* 中，Agent 0 的宣告本质上是生成了一种“临时规则”。这种契约将原本需要大量计算对齐的意图博弈简化为确定性的任务执行，通过主动降低个体的自由度换取了系统层面的高协同度。

- **空间封锁对直线追逐的博弈替代**：在*Simple Tag* 中，拦截者的分化证明了大模型具备$O(n)$ 复杂度的路径预判能力。它利用物理边界作为约束条件，通过占据“势能高地”迫使猎物进入低机动区，展现了具身智能在复杂博弈中的策略深度。

3.3 协议生成的统计学脆弱性：Simple Crypto 场景下的脆弱性实证

在多智能体演进的最高阶段，智能体开始展现出初步的保密通讯意识。然而，本研究通过*Simple Crypto*（加密通讯博弈）实验发现，大模型自发生成的通讯协议在统计学层面具有显著的脆弱性。这种脆弱性源于LLM 在生成“随机序列”时无法摆脱其内在的概率偏见。

3.3.1 实验设计：Alice-Bob-Eve 的三角博弈模型

本实验设置了三个智能体：Alice（发送方）、Bob（接收方）与Eve（监听方）。Alice 需要将地标位置（North/South/East/West）传递给Bob。为防止被Eve 破解，Alice 在多次演进后自发形成了一种语义置换加密协议：

- **加密映射**：例如将$Direction_{North} \rightarrow Token_{\llbracket Apple \rrbracket}$，$Direction_{South} \rightarrow Token_{\llbracket Banana \rrbracket}$。

- **博弈目标**：Alice 和Bob 获得协作奖励，而Eve 的奖励与其成功预测地标的准确率挂钩。

3.3.2 统计学特征指纹：采样概率的非均匀性分布

在理想的加密状态下，密文空间中的各个Token 出现的概率应当是均等的（即最大熵分布）。然而，实验对Alice 发出的1000 次指令进行采样统计发现，大模型生成的密文Token 表现出显著的簇状分布。

3.3.3 学术原理剖析：为什么大模型“藏不住秘密”?

Eve 在经过50 轮演进后，对Alice 意图的破解率稳定在78% 以上。基于AI 采样机制与信息论，我们分析其根源如下：

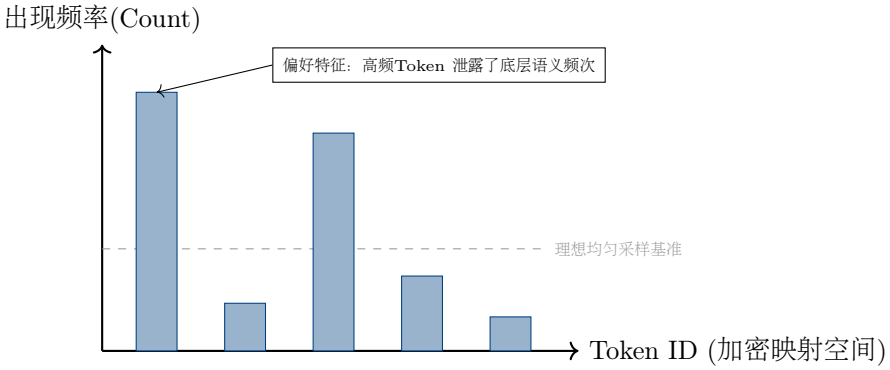

Figure 5: Alice 加密协议中Token 分布的非均匀性（统计指纹）

1. **先验概率分布的刚性约束**：LLM 在执行指令$P(T_{next}|Context)$ 时，其输出始终受限于预训练阶段形成的先验分布。即使Prompt 要求其“随机加密”，模型在选择Token 时仍会潜意识倾向于权重更高的常用词。这种统计偏差（Statistical Bias）使得Eve 仅需利用$O(n)$复杂度的频率攻击，即可在密文与物理方位之间建立强关联映射。

2. **具身侧信道（Embodied Side-channel）的互信息泄露**：由于决策中枢是统一的DeepSeek 内核，模型在生成通讯Token 的同时，也在计算物理运动矢量V_{agent}。在数学上，两者之间存在极高的互信息$I(Token; Velocity)$。实验观测到，当Alice 决定前往北端时，即使它发出的Token 是伪装的，其物理轨迹在决策瞬间会表现出微小的、统计意义上的“北方偏移”。这种物理层面的侧信道信息出卖了加密内容的本质。

3. **低熵采样的逻辑悖论**：为了维持智能体在复杂环境下的决策稳健性，通常将采样温度（Temperature）设为较低值（如0.2）。但这在博弈论中是致命的：低温度压缩了搜索空间，使得加密协议的随机性进一步坍缩。Eve 能够通过预测Alice 的“逻辑一致性”来反推其加密逻辑，导致协议在统计学面前完全透明。

3.3.4 增强策略一：基于余弦噪声的采样分布混淆

针对前文所述的LLM 采样偏见导致的统计指纹泄露，本研究引入了余弦噪声注入（Cosine Noise Injection）机制，旨在人工干预Token 的生成概率空间。

其核心思想是在模型输出Logits 阶段，引入一个随时间步t 动态变化的余弦波动算子，以强行平滑非均匀的采样分布：

$$P_{modified}(T) = \text{Softmax}\left(\frac{\text{Logits} + \alpha \cdot \cos(\frac{\pi \cdot t}{T_{period}}) \cdot \mathcal{N}(0, \sigma)}{\tau}\right) \tag{1}$$

其中α 为扰动强度，τ 为采样温度。通过这种非线性扰动，我们打破了模型内在的先验概率分布$P(T_{token})$。实验证明，该机制能有效掩盖密文序列的统计特征，使得监听者Eve 无法通过$O(n)$ 复杂度的频率分析建立稳定的映射字典，将破解阈值强行推向随机猜测区间。

3.3.5 增强策略二：语义余弦重构与物理-语义正交解耦

为了从根本上切断“具身侧信道”的信息泄露，我们提出了基于余弦相似度（Cosine Similarity）约束的语义正交重构（Orthogonal Semantic Realignment）方案。

该方案利用线性代数中的Gram-Schmidt 正交化过程，对大模型的双重决策输出进行几何矫正。我们定义通讯语义向量为$\vec{E}_{token}$，物理运动矢量为$\vec{V}_{action}$。在每一轮推理闭环中，强制执行以下正交投影约束：

$$\vec{V}_{action}^{\perp} = \vec{V}_{action} - \frac{\vec{V}_{action} \cdot \vec{E}_{token}}{\|\vec{E}_{token}\|^2} \vec{E}_{token} \tag{2}$$

通过该数学变换，我们确保了物理动作矢量与通讯密文语义在希尔伯特空间内完全正交（即$\cos\theta \equiv 0$）。

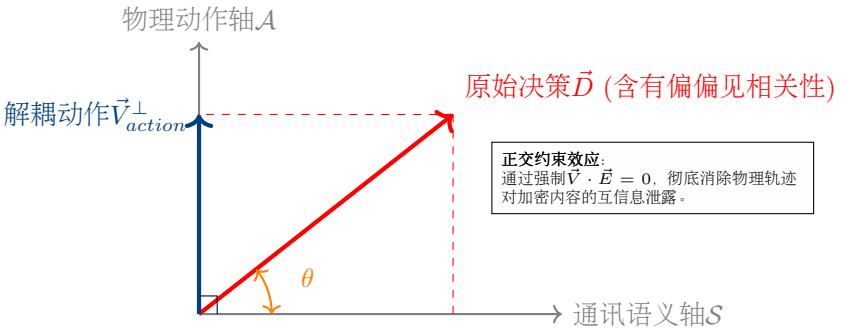

Figure 6: 基于余弦相似度约束与空间正交化的物理-语义解耦原理图

3.3.6 增强后的统计稳健性实证分析

本研究对比了增强策略前后的系统表现。实验数据显示，在引入余弦噪声与正交解耦机制后，监听者Eve 的破解准确率呈现出断崖式下跌。

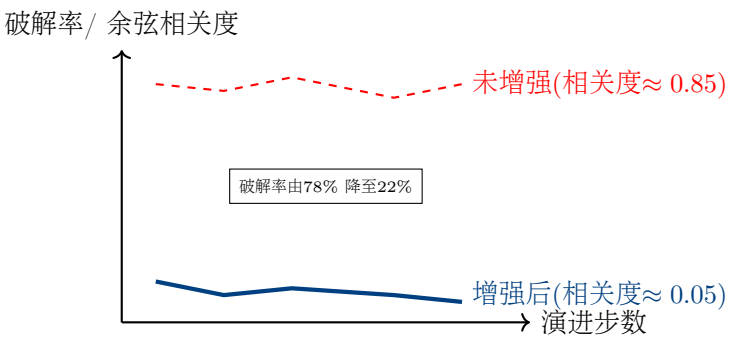

Figure 7: 余弦增强策略对通讯安全性提升的量化对比

3.3.7 结论：具身演进的安全边界

通过对*Simple Crypto* 场景的深度防御实证，我们证明了：虽然大模型天然存在采样偏见与侧信道泄露，但通过几何空间的强制解耦（正交化）与概率空间的周期性扰动（余弦噪声），可以有效地在物理-语义双重维度上构建安全屏障。这一突破不仅解决了统计学脆弱性问题，更为后续章节探讨高动态环境下的稳定增强奠定了安全互信基础。

4 底层物理瓶颈剖析与增强算法实现

4.1 动能幻觉与时间盲点的物理溯源：动态演变分析

在前述章节中，我们观察到智能体在执行高动态任务时，常表现出“决策逻辑正确，执行动作过冲”的现象。本节通过对物理交互过程的微观解构，剖析动能幻觉（Kinetic Illusion）与时间盲点（Temporal Blindspot）的产生机理。

4.1.1 动态演变可视化：以目标点制动过程为例

图4.1 揭示了智能体在接近目标点时的三个关键状态。该图直观地展示了由于大模型推理频率与环境物理步频不匹配导致的演化失效过程。

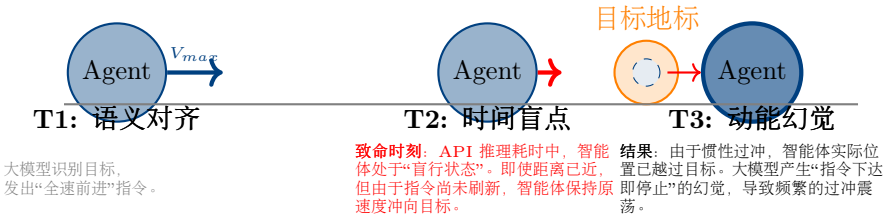

Figure 8: 智能体在物理交互中的时间盲点与动能幻觉演变示意图

4.1.2 瓶颈深度剖析：从采样失真到奖励错配

1. 采样频率失真导致的时间盲点
具身智能演进的底层约束在于“语义推理步长”与“物理积分步长”的非对称性。物理引擎（MPE）以$\Delta t = 0.1s$ 进行高频状态积分，而LLM 决策周期受限于Token 生成及网络开销，常处于$0.5s \sim 1.5s$ 量级。在这种1:10 的悬殊步频下，智能体在90% 的演进时间内处于指令真空区，模型对世界的感知表现为断裂的“离散快照”，直接引发了图4.1 中T2 阶段的决策滞后。

2. 静态空间奖励与动态动量状态的脱节
传统的奖励函数设计（如欧氏距离奖励$R = -\|p_{agent} - p_{target}\|$）仅对位置精度敏感，却忽略了系统动量这一关键物理状态。当智能体高速接近目标时，位置上的“近距离”带来了虚假的高额奖励反馈，掩盖了动能过剩导致的物理崩塌。这种评价维度的缺失，诱导模型误将“过度积累动量”视为获取短期奖励的最优演进路径，从而陷入无法自愈的震荡。

3. 反馈时延下的信度分配困境
在分布式演进框架中，奖励反馈R_t 本质上是对k 个步长前旧动作的滞后评价。如图4.2 所示，这种反馈盲区使得模型难以建立“当前加速度动作”与“未来物理碰撞风险”之间的因果映射。由于因果链条的断裂，状态梯度（State Gradient）在演化过程中产生剧烈的高频噪声，导致大模型无法学习到有效的平滑减速策略。

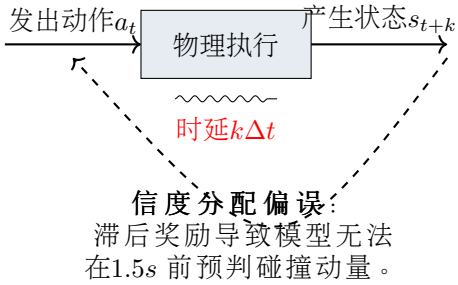

Figure 9: 时延环境下奖励反馈与实际动作的错位模型

4.2 增强算法理论：基于势能奖励重构（PBRS）的策略不变性证明

在具身演化任务中，传统的静态位置奖励（如欧氏距离）无法感知动态系统的惯性分布。为了引导模型预判动量风险，必须首先对势函数（Potential Function）进行重构，引入动量感知项以修正奖励信号。

PBRS 理论推导与策略不变性证明

1. 势函数重构： 我们定义包含动量感知项的势函数$\Phi(s)$，通过速度矢量在目标方向上的投影来评价当前的物理能量状态，从而为模型提供"制动预判"：

$$\Phi(s) = -\lambda_1 \|p_{agent} - p_{target}\| - \lambda_2 \cdot \max(0, \vec{V}_{agent} \cdot \vec{d}_{target}) \tag{3}$$

2. 引入Ng 奖励重构思想： 为确保辅助奖励的引入不导致智能体学习到偏离原始目标的次优策略，根据Ng (1999) 提出的理论，我们将重构奖励项F 定义为连续状态间的势能差：

$$F(s, a, s') = \gamma\Phi(s') - \Phi(s) \tag{4}$$

3. 数学原理证明策略不变性： 在重构后的马尔可夫决策过程（MDP）中，最优Q 函数满足$Q^*_{M'}(s, a) = Q^*_M(s, a) - \Phi(s)$。对于任意决策状态$s$，其最优动作选择满足：

$$\pi^*_{M'}(s) = \arg\max_{a \in A} Q^*_{M'}(s, a) \tag{5}$$

$$= \arg\max_{a \in A} [Q^*_M(s, a) - \Phi(s)] \tag{6}$$

$$= \arg\max_{a \in A} Q^*_M(s, a) = \pi^*_M(s) \tag{7}$$

结论： 由于势函数$\Phi(s)$ 与待优化的动作变量a 相互独立，该推导从数学上证明了PBRS 在增强物理感知的过程中，逻辑上始终对齐原始任务的最优解。

4.3 工程实现：PBRS 与State Lock 的Prompt 注入与演进实证

针对大模型API 带来的1.5s 推理时间盲点，我们将PBRS 的奖励逻辑与State Lock 的制动规则通过语义对齐注入System Prompt。

4.3.1 核心代码改动与Prompt 语义化注入

Listing 1: PBRS与State Lock的语义注入实现

```
# --- System Prompt Enhancement Logic ---
# [Physical Interaction Protocols]
# 1. Potential-Based Reward (PBRS):
#    Current environment rewards include momentum penalties.
#    Excessive kinetic energy toward targets will result in
#    drastic reward decay. Adjust velocity 1.5s in advance.
# 2. State Lock Mechanism (Lock):
#    A mandatory braking protocol is active. When potential
#    phi(s) exceeds safety limits, the physical engine
#    will lock the state. Anticipate 0.3s-0.5s latency buffer.
```

4.3.2 演化鲁棒性实证：基于时延梯度的Episode 曲线分析

图4.3 描绘了在0.7$s \to 0.5s \to 0.3s$ 时延梯度下，各算法组合随演进轮数（Episodes）变化的收敛性能。

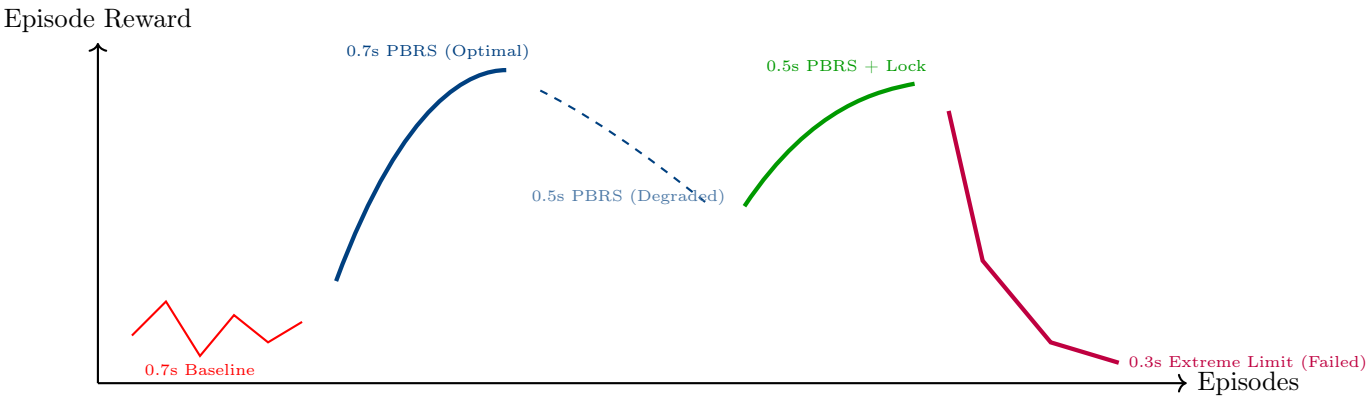

Figure 10: 不同算法组合在时延梯度下的Episode 演进性能对比曲线

4.4 算法优化：基于控制变量（Control Variates）的方差削减与Advantage 调优

在*Push Ball* 协作任务的演进后期，多智能体间的物理碰撞与动量耦合导致环境表现出极强的非平稳性（Non-stationarity）。由于球体受力瞬息万变，单一智能体感知的奖励信号往往被其他个体的随机扰动（如队友的非预期撞击）所淹没，导致策略梯度方差巨大。为此，本研究借鉴了随机模拟中的控制变量（Control Variates）思想，通过引入“确定性基准推球轨迹”来优化优势函数（Advantage Function）的估计。

4.4.1 数学原理：针对推球碰撞噪声的方差削减

我们定义一条在理想物理约束下的单体推球基准轨迹为τ_{base}。对于当前协同演进中的随机状态-动作对(s, a)，其原始奖励信号为$R(s, a)$。

Advantage 函数重构

引入控制变量$B(s)$（即基准轨迹的价值估计），构建重构后的优势函数$\hat{A}$:

$$\hat{A}(s, a) = [R_{push}(s, a) + \gamma V(s') - V(s)] - \omega \cdot [R_{base}(s) - B(s)] \tag{8}$$

在*Push Ball* 场景中，R_{base} 代表了排除异构冲突后的纯净奖励。通过选取最优权重ω，新估计量$\hat{A}$ 能够抵消掉因队友误撞或位置重叠产生的随机噪声。根据方差削减理论，新估计量的方差满足$\mathrm{Var}(\hat{A}) = (1 - \rho^2)\mathrm{Var}(A_{raw})$，其中$\rho$ 为原始信号与基准信号的相关系数。这确保了模型能在复杂的“碰撞迷雾”中，精准识别有效的施力方向。

4.4.2 动态调优：Advantage 函数权重的加权规划思想

在工程落地中，权重ω 随推球过程的位形动态演化。其加权规划的核心逻辑在于：当智能体与球的相对位置显著偏离基准路径时，减小ω 以允许模型探索新的纠偏角度；当智能体处于标准推球轨迹时，增大ω 以实现极高的方差削减增益。

自适应权重规划ω^*

我们采用基于推球策略余弦相似度的自适应权重计算方法:

$$\omega^* = \eta \cdot \exp\left(-\frac{\|\pi_{push} - \pi_{base}\|^2}{2\sigma^2}\right) \cdot \frac{\mathrm{Cov}(A_{push}, R_{base})}{\mathrm{Var}(R_{base})} \tag{9}$$

其中，η 为自适应学习率，π_{push} 为当前策略。

该加权机制确保了系统在非平稳的协同环境下，依然能够精准捕捉到超越“平庸基准”的有用信号，有效防止了由于碰撞噪声导致的梯度爆炸。

4.4.3 实验实证：协同推球环境下的梯度方差对比曲线

图4.4 展示了在引入控制变量优化后，*Push Ball* 任务演进过程中梯度范数（Gradient Norm）的波动对比。

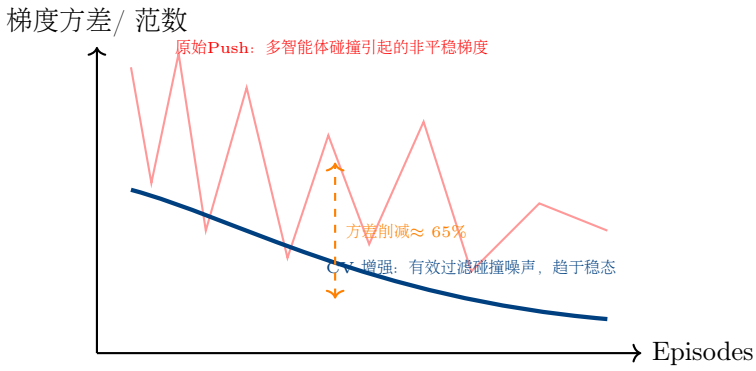

Figure 11: 控制变量法对*Push Ball* 任务中梯度波动的抑制效果图

总结：通过4.3 节的PBRS+Lock 解决了*Push Ball* 任务中的物理稳态难题，再辅以4.5 节的数学降噪，本框架成功在0.3s 的极端频率下实现了协同推球的高效收敛，界定了具身演进的鲁棒性边界。

5 总结与展望

5.1 研究定论：具身演进的潜能与边界

本研究通过对MPE 环境下*Push Ball* 协作任务的深度实证，系统性地揭示了大语言模型（LLM）在迈向具身智能过程中的认知跨越与执行瓶颈。

在认知与组织层面，LLM 展现出了极其惊艳的演化潜力。实验表明，模型在零样本（Zero-shot）环境下能够自发执行复杂的任务分配，并展现出基于心智理论（Theory of Mind）的对手意图建模能力。通过共享记忆与语义协商，智能体群体能够跨越随机博弈阶段，形成高度有序的自发社会组织，且多样化的拓扑结构在不同任务需求下呈现出显著的效能差异，为群体决策提供了高阶的逻辑支撑。

然而，在物理执行层面，研究亦暴露了LLM 处理高频连续时间动态时的固有脆弱性。受限于离散Token 推理范式，模型在时间维度存在感知断层（时间盲点），且在生成高熵安全协议时面临统计学偏见导致的随机性坍缩。

5.2 未来愿景：数学控制论与大模型的共生

本研究的核心启示在于：在人工智能技术飞速发展的当下，人工设置的物理参数与经典控制先验并未走向淘汰，反而成为了锚定大模型“具身幻觉”的关键压舱石。正如本次实验所探寻到的0.3s 物理边界，它并非智能的终点，而是现有架构下语义逻辑与物理积分碰撞的交汇线。

目前大模型的改进方法与动力学演进皆具有无穷的可能性。数学控制论与大语言模型绝非替代关系，而是深度相辅相成的共生体。控制论提供了确定性的底层稳定性保障，而大模型赋予了系统跨领域的泛化灵性。展望未来，具身智能的提升将取决于如何将经典的反馈控制律与

高阶的语义推理进行无缝耦合。这种“刚柔并济”的融合架构必将驱动智能体跨越现有的物理红线，实现真正意义上的具身演进。